

Artigo

Aplicação e avaliação de métodos de agrupamento em conjuntos de dados de naturezas distintas

Bernardo Schaffazick Caetani ¹, Cristiano de Castro Nunes ²

¹ Programa de Pós-Graduação em Engenharia Elétrica, Universidade Federal do Rio Grande do Sul
bcaetani.poa@gmail.com

² Programa de Pós-Graduação em Engenharia Elétrica, Universidade Federal do Rio Grande do Sul
cristiano.nunes@ufrgs.br

Prof. Dr. Alexandre Balbinot
ELE0318 - Inteligência Computacional I
Junho de 2026

Resumo: Este trabalho aplica e avalia técnicas de agrupamento não supervisionado, com ênfase no algoritmo k-means, sobre três conjuntos de dados públicos de naturezas distintas. Em um conjunto de características geométricas de grãos de trigo, com classes conhecidas a priori, o k-means precedido de análise de componentes principais recuperou as espécies com alta fidelidade. Em um conjunto exploratório de transações semanais de vendas, o método revelou grupos de produtos com tendências de venda qualitativamente diferentes ao longo do ano. Em um conjunto de consumo residencial de energia elétrica, a caracterização dos perfis diários convergiu para uma partição com clara interpretação sazonal, validada por classificação supervisionada e contrastada com o agrupamento hierárquico. Os resultados demonstram que o k-means é adequado tanto para validar estruturas conhecidas quanto para explorar padrões latentes, desde que precedido de pré-processamento apropriado.

1. Introdução

A aprendizagem não supervisionada ocupa papel central na análise de dados quando não há rótulos disponíveis ou quando se pretende investigar a estrutura de um conjunto de observações. Entre as técnicas mais utilizadas nesse contexto, os métodos de agrupamento se destacam por permitir a identificação de grupos de elementos semelhantes segundo critérios de proximidade no espaço de características. Dentre esses métodos, o algoritmo k-means permanece como uma das abordagens mais difundidas devido à sua simplicidade conceitual e boa capacidade de síntese em problemas com grande volume de dados, embora seu desempenho dependa de hipóteses sobre a geometria dos grupos e da qualidade da representação dos dados de entrada [1,2].

Apesar de sua ampla adoção, a aplicação adequada do k-means exige decisões que influenciam diretamente a qualidade da partição obtida. Em particular, a presença de variáveis correlacionadas, escalas heterogêneas e ruído pode comprometer a separação entre grupos, tornando o pré-processamento uma etapa fundamental da análise. Nesse sentido, técnicas de redução de dimensionalidade, como a análise de componentes principais, podem favorecer a interpretação dos resultados. De modo complementar, a escolha do número de grupos e a avaliação da consistência das partições constituem aspectos essenciais em estudos de agrupamento [3,4].

Neste contexto, este trabalho tem por objetivo aplicar e avaliar técnicas de agrupamento não supervisionado, com ênfase no algoritmo k-means, sobre três conjuntos de dados públicos de naturezas distintas, de modo a explorar tanto a capacidade do método de recuperar estruturas conhecidas quanto a de revelar padrões previamente desconhecidos. Para isso, são considerados um conjunto de características geométricas de grãos de trigo, um conjunto de transações semanais de

vendas e um conjunto de consumo residencial de energia elétrica, de forma a contemplar diferentes contextos analíticos. Assim, o estudo pretende oferecer uma avaliação abrangente da utilidade do algoritmo como ferramenta de interpretação de estruturas presentes em bases de dados heterogêneas.

2. Metodologia

As implementações elaboradas no presente trabalho foram desenvolvidas e validadas utilizando a linguagem de programação *Python* em sua versão 3.12.3, com as bibliotecas e suas respectivas versões expostas na Tabela 1.

Tabela 1. Bibliotecas utilizadas e suas respectivas versões.

Biblioteca	Versão
<i>pandas</i>	3.0.3
<i>openpyxl</i>	3.1.5
<i>numpy</i>	2.4.6
<i>scikit-learn</i>	1.8.0
<i>matplotlib</i>	3.10.8

Fonte: Autores (2026).

2.1. Agrupamento de Dados de Consumo Residencial de Energia Elétrica

Inicialmente, com vistas à seleção de uma das bases, realizou-se a análise de dois conjuntos de dados públicos disponibilizados pela University of California, Irvine (UCI):

Tabela 2. Especificação das bases de dados.

Base	Atributos	Dados	Descrição
KDD Cup 1998 [5]	33	4.898.431	Conexões de rede em ambiente militar
Household Electric Power [6]	7	2.075.259	Consumo residencial por minuto

Fonte: Balbinot (2026).

Quanto à dimensionalidade, a base de consumo residencial de energia possuía 7 atributos numéricos, sem variáveis categóricas que exigiriam codificação especial, tornando direta a aplicação de métricas como a distância euclidiana. No caso da base da KDD Cup 1998, esta apresentava 33 atributos com natureza mista (numérica e categórica), além de alta esparsidade. A semântica de detecção de intrusão dessa base exigiria pré-processamento de maior complexidade, além de estar mais associada à classificação supervisionada do que ao agrupamento não supervisionado. Outro ponto a ser considerado na base de consumo residencial de energia é sua estrutura temporal, cobrindo 47 meses (dezembro de 2006 a novembro de 2010), permitindo, através de agregação temporal, a produção de perfis diários. Por fim, o próprio repositório da UCI classifica essa base como adequada para a tarefa de agrupamento, enquanto que a KDD Cup 1998 está associada apenas à tarefa de regressão.

2.1.1. Descrição, Pré-processamento e Normalização dos Dados

O conjunto de dados contém medições de consumo elétrico de uma única residência em Clamart, França, com frequência de amostragem de um minuto. A Tabela 3 apresenta as características originais, com aproximadamente 1,25% das linhas contendo valores ausentes, representados pelo caractere '?'. O arquivo é delimitado por ponto e vírgula (;). As colunas Date e Time foram

Tabela 3. Descrição dos atributos do conjunto de dados

Atributo	Unidade	Descrição
Global_active_power	kW	Potência ativa global (média por minuto)
Global_reactive_power	kW	Potência reativa global (média por minuto)
Voltage	V	Tensão elétrica (média por minuto)
Global_intensity	A	Corrente elétrica (média por minuto)
Sub_metering_1 (SM1)	Wh	Cozinha (lava-louça, forno, micro-ondas)
Sub_metering_2 (SM2)	Wh	Lavanderia (máquina de lavar, secadora, geladeira)
Sub_metering_3 (SM3)	Wh	Aquecedor de água elétrico e ar-condicionado

Fonte: Autores (2026).

combinadas em um índice temporal do tipo `datetime`, com formato `'dd/mm/yyyy HH:MM:SS'`. O valor `'?` foi substituído por `'NaN'`.

Lacunas de até 5 minutos consecutivos foram imputadas por propagação do último valor válido, procedimento adequado para séries temporais de alta frequência com falhas de sensor de curta duração. Lacunas mais longas foram removidas por `dropna()`. A fração removida foi inferior a 1,5% do total de registros. Dado que a tarefa busca identificar padrões de comportamento de consumo, a unidade de análise mais adequada não é o minuto individual, mas o perfil diário, representado por um vetor que resume o comportamento de toda a jornada. A agregação foi realizada por `'resample('D')` com funções apresentadas na Tabela 4.

Tabela 4. Atributos resultantes após agregação diária

Atributo resultante	Operação	Interpretação
total_active_power	Soma	Energia ativa total consumida no dia
total_reactive_power	Soma	Energia reativa total no dia
mean_voltage	Média	Nível médio de tensão no dia
mean_intensity	Média	Corrente média no dia
total_sm1	Soma	Energia consumida na cozinha
total_sm2	Soma	Energia consumida na lavanderia
total_sm3	Soma	Energia consumida em aquecimento/HVAC

Fonte: Autores (2026).

Um oitavo atributo foi derivado da equação fornecida na documentação da UCI [6]:


$$SM_other_d = \frac{GAP_d \times 1000}{60} - SM1_d - SM2_d - SM3_d$$

Onde GAP_d é a soma da potência ativa global no dia d (em kW). Este atributo representa o consumo de equipamentos não monitorados individualmente pelos sub-medidores, e é truncado em zero para evitar valores negativos por arredondamento. Dias com menos de 1.200 minutos de medição efetiva (equivalente a 83% do dia) foram excluídos, resultando em 1.420 perfis diários válidos para análise, cobrindo o intervalo de 17 de dezembro de 2006 a 26 de novembro de 2010.

Os oito atributos operam em escalas numéricas muito distintas. Por exemplo, `mean_voltage` varia em torno de [220, 255] V, enquanto `total_sm3` pode atingir valores da ordem de 5.000 Wh por dia. Sem normalização, a distância Euclidiana seria dominada pelas variáveis de maior magnitude, tornando as demais irrelevantes.

A técnica adotada foi a padronização Z-score:

Figura 1. Gráficos das quatro métricas: Inércia (WCSS), Coeficiente de Silhueta, Índice Calinski-Harabasz e Índice Davies-Bouldin. Cada subgráfico apresenta uma linha tracejada vertical indicando o valor de k ótimo pelo respectivo critério.



Fonte: Autores (2026).

$$z_i = \frac{x_i - \mu_i}{\sigma_i}$$

Onde μ_i e σ_i são, respectivamente, a média e o desvio padrão do atributo i calculados sobre todos os perfis diários. Após a transformação, cada atributo possui média zero e desvio padrão unitário, garantindo contribuição igualitária de todas as dimensões no cálculo das distâncias.

2.1.2. Seleção do Número de Clusters

A determinação de k é um dos problemas principais do agrupamento não supervisionado. Para este projeto, quatro métricas foram calculadas para $k \in \{2, 3, \dots, 10\}$. A primeira delas foi o método do cotovelo, que identifica o valor de k a partir do qual o ganho marginal em redução da inércia começa a diminuir significativamente, formando um "cotovelo" no gráfico $WCSS(k) \times k$. A inércia $WCSS(k)$, do inglês *Within-Cluster Sum of Squares*, é a soma dos quadrados intra-cluster minimizada pelo algoritmo k-Means:

$$WCSS(k) = \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \mu_i\|^2$$

Na sequência, tem-se o Coeficiente de Silhueta [8], que quantifica a coesão intra-cluster e a separação inter-cluster de cada observação:

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Onde:

- $a(i)$ = distância média do ponto i aos demais pontos do mesmo cluster (coesão).
- $b(i)$ = menor distância média do ponto i a todos os pontos do cluster mais próximo (separação).

O Coeficiente de Silhueta médio $\bar{S}$ pertence ao intervalo $[-1, 1]$:

- $\bar{S} \approx 1$: clusters compactos e bem separados.
- $\bar{S} \approx 0$: sobreposição entre clusters.
- $\bar{S} < 0$: observações provavelmente atribuídas ao cluster errado.

O valor de k que maximiza $\bar{S}$ é considerado o k ótimo pelo critério de silhueta.

A terceira métrica, o índice Calinski-Harabasz (CH) [9] é definido como a razão entre a dispersão inter-cluster e a dispersão intra-cluster:

$$CH(k) = \frac{\text{tr}(B_k)/(k-1)}{\text{tr}(W_k)/(n-k)}$$

Onde B_k é a matriz de dispersão entre clusters, W_k é a matriz de dispersão intra-cluster, e n é o número total de observações. Valores maiores indicam clusters mais densos e bem separados.

A última métrica é o índice Davies-Bouldin (DB) [10], que mede a similaridade média entre cada cluster e seu vizinho mais semelhante:

$$DB(k) = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left\{ \frac{\bar{d}_i + \bar{d}_j}{d(\mu_i, \mu_j)} \right\}$$

Onde $\bar{d}_i$ é a distância média dos pontos do cluster i ao seu centróide. Valores menores indicam clusters melhor separados, e o valor mínimo é zero. O valor de k ótimo de acordo com cada um dos quatro critérios pode ser visto na Figura 1.

Para os valores de k candidatos ($k \in \{2, 3, 4, 5\}$), foram gerados também gráficos de silhueta por amostra, em que as observações são ordenadas dentro de cada cluster pelo valor de $S(i)$ e representadas em faixas coloridas. A Figura 2 mostra esses gráficos, nos quais clusters de boa qualidade devem apresentar a maioria das amostras com coeficiente superior à média e acima de zero.


2.1.3. Algoritmo k-Means

O algoritmo k-Means [11] foi executado com inicialização k-Means++, na qual os k centróides iniciais são selecionados com probabilidade proporcional à distância ao quadrado do ponto mais próximo já selecionado, reduzindo o risco de convergência para mínimos locais. Foram definidos também $n_init = 15$, $max_iter = 300$ e $random_state = 42$: o primeiro reinicia o algoritmo 15 vezes com diferentes inicializações, e a solução com menor WCSS é retida; o segundo é o critério de parada por número máximo de iterações; o terceiro corresponde à semente fixa para reprodutibilidade.

Em cada iteração, o k-Means alterna entre dois passos até a convergência: o passo de atribuição, no qual cada observação x é associada ao centróide mais próximo, e o passo de atualização, no qual os centróides são recalculados como a média dos pontos atribuídos. O algoritmo converge quando nenhuma observação muda de cluster entre iterações consecutivas, ou quando max_iter é atingido.

A projeção dos perfis diários no plano bidimensional foi realizada por Análise de Componentes Principais (PCA), retendo os dois primeiros componentes, que explicam a maior fração da variância do espaço de 8 dimensões. Os centróides foram projetados no mesmo espaço via $W^\top \mu_i$, onde W é a matriz de carregamentos da PCA. A Figura 3 exibe, na esquerda, o *scatter plot* das projeções PCA

Figura 2. Gráficos de silhueta por amostra para $k = 2, 3, 4, 5$. Em cada subgráfico, as observações são agrupadas por cluster e ordenadas pelo coeficiente de silhueta $S(i)$. A linha tracejada vermelha marca a média $\bar{S}$.




Fonte: Autores (2026).

colorido por rótulo de cluster, com os centróides marcados por estrelas pretas. Na direita é possível ver o mesmo *scatter* colorido por estação do ano, permitindo verificar se os clusters apresentam correspondência temporal. Já a Figura 4 mostra a distribuição mensal de cada cluster ao longo dos 47 meses, na qual se observa predominância de clusters de alto consumo nos meses de inverno (dezembro a fevereiro) e de baixo consumo nos meses de verão (junho a agosto).

2.1.4. Classificador k-NN


O k-NN (*k-Nearest Neighbours*) é originalmente um algoritmo de classificação supervisionada, ou seja, dado um conjunto de treinamento com rótulos, ele atribui a um novo ponto a classe mais frequente entre seus k vizinhos mais próximos. Neste trabalho, o k-NN é aplicado em um papel secundário e de validação, de forma que após o k-Means descobrir k clusters não supervisionados, os rótulos de cluster são usados como classes-alvo de um classificador k-NN. Essa abordagem permite avaliar se o k-NN consegue reproduzir os rótulos com alta *accuracy*, significando que os clusters são geometricamente compactos e bem separados. Além disso, pode-se demonstrar os efeitos de *over* e *underfitting*, já que com $k = 1$, o classificador memoriza perfeitamente os dados de treino (*accuracy* = 1,0) mas pode não generalizar. Com k muito alto, os limites de decisão tornam-se excessivamente suavizados e a acurácia de treino e teste convergem para valores inferiores.

Figura 3. Scatter plot das projeções PCA colorido por rótulo de cluster (esquerda) e colorido por estação do ano (direita).



Fonte: Autores (2026).

Figura 4. Distribuição mensal de cada cluster ao longo dos 47 meses.




Fonte: Autores (2026).

A base de perfis diários foi dividida em conjuntos de treino (80%) e teste (20%) com estratificação por rótulo de cluster, preservando as proporções originais. A métrica de distância adotada foi a distância Euclidiana, operando no espaço normalizado. O parâmetro k foi varrido de 1 a 20. Para cada valor, foram computadas a *accuracy* de treino e teste. O k ótimo foi selecionado como aquele que maximiza a *accuracy* no conjunto de teste, evitando *overfitting* (k muito pequeno) e *underfitting* (k muito grande). A regra geral de ponderação uniforme foi adotada, com todos os vizinhos tendo peso igual. A validação cruzada (CV) com 10 *folds* foi realizada para estimar a *accuracy* de generalização de forma mais robusta do que a divisão única treino-teste.

2.1.5. Agrupamento Hierárquico e Dendogramas

O k-Means é um algoritmo de agrupamento particionado, isto é, requer a especificação prévia de k e produz apenas uma partição final. O agrupamento hierárquico aglomerativo constitui uma abordagem complementar que não exige a especificação prévia de k , produz uma hierarquia completa de fusões representada por um dendrograma e permite visualizar a estrutura de aninhamento dos clusters em múltiplos níveis de granularidade.

O agrupamento hierárquico aglomerativo parte de n clusters *singleton* (um por observação) e, a cada iteração, funde os dois clusters com menor dissimilaridade, até que reste um único cluster

Figura 5. Dendrogramas das Ligações de Ward (esquerda), Completa (centro) e Média (direita).

Fonte: Autores (2026).

contendo todas as observações. A escolha do critério de ligação determina como a dissimilaridade entre dois clusters é calculada. Dentre os três critérios avaliados, estão a Ligação de Ward, que minimiza o incremento na variância total intra-cluster resultante de cada fusão, a Ligação Completa, na qual a dissimilaridade entre dois clusters é definida pela maior distância entre qualquer par de pontos dos dois clusters, e a Ligação Média, que utiliza a média de todas as distâncias par a par entre os dois clusters.

O conjunto completo de aproximadamente 1.400 perfis diários produziria um dendrograma ilegível. Uma amostra estratificada de 300 dias (em torno de 75 por estação do ano) foi selecionada aleatoriamente, preservando as proporções sazonais e garantindo representatividade dos padrões de consumo ao longo do ano. No dendrograma, o eixo vertical representa a distância (ou dissimilaridade) de fusão. Para determinar k clusters a partir do dendrograma, traça-se uma linha horizontal (*cut line*) no nível de distância imediatamente superior à lacuna mais larga entre fusões consecutivas (o chamado maior salto de dissimilaridade). O número de ramos cortados por essa linha corresponde a k .


A Figura 5 exibe os três dendrogramas mencionados acima. Cada dendrograma exibe os 50 últimos agrupamentos, com contagem de folhas entre parênteses. A legenda de cada subgráfico identifica o critério de ligação. Ainda, a Figura 6 mostra o dendrograma da Ligação de Ward ampliado (80 ramos visíveis), com maior resolução horizontal. A linha tracejada vermelha nas figuras foi posicionada levemente acima da distância da $(k - 1)$ -ésima última fusão no dendrograma de Ward.

2.2. Coeficiente de Inconsistência

Um coeficiente de inconsistência elevado ($c_i \gg 1$) para uma determinada fusão i indica que a altura h_i daquela fusão é significativamente superior à média das alturas na sua vizinhança hierárquica imediata. Isso significa que a fusão i une dois grupos que, nos níveis inferiores do dendrograma, estavam sendo mesclados a distâncias muito menores. O salto abrupto em h_i revela que a fusão está conectando dois grupos genuinamente distintos, ou seja, uma fronteira cluster-cluster, e não uma fusão intra-cluster.

Ainda, ao fundir os dois grupos naquele nível, introduz-se um grau de heterogeneidade interna muito maior do que o esperado com base no comportamento local da hierarquia. Um limiar típico é $c_i > 1,0$ a $c_i > 1,2$, acima do qual a fusão é considerada um ponto de corte natural. Quando $c_i \approx 0$, a fusão é perfeitamente consistente com o padrão local: trata-se de uma fusão intra-cluster homogênea. Coeficientes próximos de zero ocorrem tipicamente nas fusões de baixo nível (entre

Figura 6. Dendrograma da Ligação de Ward ampliado.



Fonte: Autores (2026).

observações muito próximas), enquanto os coeficientes mais elevados concentram-se nas fusões de alto nível que separam os grandes grupos.

O coeficiente de inconsistência é, portanto, uma medida de quão anômala é determinada fusão em relação ao seu entorno hierárquico imediato. Uma fusão decisiva (aquela que une os dois principais grupos) tende a apresentar o maior coeficiente entre as fusões do topo do dendrograma.

Para um dado nó i e profundidade de vizinhança d , define-se o conjunto $\mathcal{V}(i, d)$ como o conjunto de todas as fusões pertencentes à subárvore de profundidade d enraizada em i (excluindo-se o próprio nó i). A profundidade d controla o raio da vizinhança e, com $d = 2$ (padrão do `scipy`), cada coeficiente é calculado com base nas fusões localizadas até dois níveis hierárquicos abaixo do nó avaliado. Valores maiores de d suavizam o coeficiente ao ampliar a vizinhança, reduzindo a sensibilidade a variações locais. Para este trabalho, portanto, adotou-se $d = 2$.

2.2.1. Manipulação dos Dados e Ligação de Ward

O conjunto de dados e o processo de pré-processamento são idênticos aos da Subseção 2.1.1. Entretanto, diferentemente de lá, em que o agrupamento hierárquico foi aplicado sobre uma amostra estratificada de 300 dias (por limitações de visualização do dendrograma), neste estágio a Ligação Ward é calculada sobre os 1420 perfis completos, possibilitando uma análise de inconsistência mais representativa do *dataset*.

O método de Ward minimiza a variância intra-cluster a cada fusão, maximizando a compacidade dos grupos formados. A distância de Ward entre dois clusters $\mathcal{A}$ e $\mathcal{B}$ é:

$$d_W(\mathcal{A}, \mathcal{B}) = \sqrt{\frac{2n_{\mathcal{A}}n_{\mathcal{B}}}{n_{\mathcal{A}} + n_{\mathcal{B}}}} \|\mu_{\mathcal{A}} - \mu_{\mathcal{B}}\|_2$$

Onde $\mu_{\mathcal{A}}$ e $\mu_{\mathcal{B}}$ são os centroides e, $n_{\mathcal{A}}$ e $n_{\mathcal{B}}$, os tamanhos dos clusters. A implementação utiliza `scipy.cluster.hierarchy.linkage(X, method='ward', metric='euclidean')`, que opera sobre a representação condensada da matriz de distâncias. A matriz de Ligação resultante Z tem dimensão 1419×4 , representando as 1419 fusões sequenciais necessárias para fundir 1420 observações em um único cluster raiz.

2.2.2. Cálculo dos Coeficientes de Inconsistência

Com a matriz Z calculada, aplica-se a função `scipy.cluster.hierarchy.inconsistent(Z, d=2)`, obtendo-se a matriz de inconsistência I de dimensão 1419×4 . As estatísticas globais do coeficiente para esta base de dados são:

- Coeficiente máximo: $c_{\max} = 1,1547$
- Coeficiente médio: $\bar{c} = 0,5608$
- Coeficiente mediano: $\tilde{c} = 0,7071$

Observa-se que a amplitude dos coeficientes ($[0; 1,155]$) é relativamente estreita, o que reflete a natureza gradual das transições sazonais presentes nos dados. As últimas 15 fusões (as de maior altura, que unem os grandes grupos) estão sumarizadas na Tabela 5. Ainda, a Figura 7 apresenta o perfil completo do coeficiente de inconsistência ao longo de todas as 1419 fusões (esquerda) e uma ampliação das últimas 60 fusões de maior nível hierárquico (direita). O ponto vermelho marca a fusão inter-cluster decisiva correspondente a $k = 2$.

Tabela 5. Últimas 15 fusões do dendrograma Ward

Índice	Altura	Média	Desvio Padrão	Coeficiente
1404	14,3931	10,8788	3,4467	1,0196
1405	14,5949	12,4020	1,9641	1,1165
1406	14,6847	12,1963	3,3147	0,7507
1407	16,9552	11,5868	4,6770	1,1478
1408	16,9931	12,9524	3,7211	1,0859
1409	18,1168	11,8789	5,5611	1,1217
1410	21,5915	16,6077	5,1873	0,9608
1411	22,4060	16,1024	5,7013	1,1056
1412	23,9923	18,2788	5,1801	1,1030
1413	27,6366	18,9048	7,5634	1,1545
1414	33,2572	24,0402	11,4471	0,8052
1415	35,2733	26,4236	7,6749	1,1531
1416	37,7418	29,7053	10,2833	0,7815
1417	46,9491	35,4049	11,4789	1,0057
1418	75,9822	53,5577	19,9584	1,1236

Fonte: Autores (2026).

2.2.3. Determinação do Número de Clusters

No presente trabalho, dois métodos são adotados para determinação do número de clusters. No primeiro, para cada candidato $k \in \{2, 3, \dots, 16\}$, identifica-se a fusão decisiva $i^*(k)$, isto é, a fusão de mais alto nível que seria eliminada ao cortar o dendrograma para obter k grupos. Formalmente, para uma matriz de Ligação com $n_{\text{fusões}}$ linhas, a fusão decisiva para k clusters está no índice:


$$i^*(k) = n_{\text{fusões}} - k + 1$$

Para cada $i^*(k)$, é calculado:

- h_{i^*} , a altura da fusão (distância de Ward)
- c_{i^*} , o coeficiente de inconsistência
- $\Delta h(k) = h_{i^*(k)} - h_{i^*(k-1)}$, o salto de altura em relação à fusão imediatamente abaixo

O k com o maior salto de altura $\Delta h(k)$ identifica a fronteira mais pronunciada na hierarquia, correspondendo ao ponto onde a fusão próxima é proporcionalmente a mais disruptiva. Os

Figura 7. Perfil do coeficiente de inconsistência para todas as fusões da Ligação de Ward (esquerda) e ampliação das últimas 60 fusões (direita).



Fonte: Autores (2026).

resultados para $k = 2$ a $k = 7$ são apresentados na Tabela 6. Os demais são omitidos por apresentarem valores menores de $\Delta h(k)$.

Tabela 6. Fusão decisiva por candidato k do primeiro método.

k	h_{i^*}	c_{i^*}	Δh
2	75,9822	1,1236	29,0331
3	46,9491	1,0057	9,2073
4	37,7418	0,7815	2,4684
5	35,2733	1,1531	2,0161
6	33,2572	0,8052	5,6206
7	27,6366	1,1545	3,6443


Fonte: Autores (2026).

O salto de altura máximo ($\Delta h = 29,03$) ocorre em $k = 2$, indicando que a fusão raiz une dois grupos que já acumulavam uma variância intra-cluster de 46,95 em separado, e a sua junção eleva essa variância para 75,98. O segundo maior salto ($\Delta h = 9,21$) é para $k = 3$, mas é três vezes menor, confirmando a dominância de $k = 2$ como fronteira natural para o primeiro método.

Para o segundo método, do maior salto entre alturas consecutivas, complementarmente são calculadas as diferenças $\Delta_i = h_{i+1} - h_i$ entre as alturas de fusões consecutivas nas últimas 15 fusões do dendrograma. O maior salto identifica o intervalo de altura onde se deve posicionar o corte:

$$\Delta_{\max} = \arg \max_i \Delta_i$$

O maior $\Delta = 29,03$ ocorre entre a fusão de índice 1417 (altura 46,95) e a fusão raiz (índice 1418, altura 75,98). O corte posicionado acima da fusão 1417, portanto excluindo apenas a fusão raiz e produzindo exatamente $k = 2$ grupos. Com base nos dois métodos, seleciona-se $k = 2$ como o número de clusters mais natural para esta base de dados. A composição resultante é 667 dias (47,0%) para o Cluster 0 e 753 dias (53,0%) para o Cluster 1.

Figura 8. Dendrograma Ward truncado com corte determinado pelo coeficiente de inconsistência.

Fonte: Autores (2026).

2.2.4. Dendrograma e Matrizes de Dispersão

A Figura 8 apresenta o dendrograma de Ward truncado nas últimas 60 fusões (modo 1astp, com contagem de folhas), colorido pelo limiar de corte posicionado entre as alturas 46,95 e 75,98 (ponto médio = 61,46). A linha tracejada vermelha marca o ponto de corte, e o coeficiente de inconsistência da fusão decisiva (1,1236) é exibido na legenda. Nós coloridos representam os dois agrupamentos, enquanto que nós acima do limiar são exibidos em cinza.

Já a matriz de dispersão (SPLOM) é uma representação gráfica que exhibe, em forma de grade $p \times p$, os diagramas de dispersão de todos os pares de atributos de um conjunto de dados p -dimensional. Para $p = 8$ atributos, produz-se uma grade $8 \times 8 = 64$ painéis, onde os painéis fora da diagonal (i, j) , $i \neq j$, exibem o diagrama de dispersão do atributo j (eixo x) em função do atributo i (eixo y), colorido por cluster. Os painéis na diagonal (i, i) exibem a distribuição marginal do atributo i , sob a forma de estimativa de densidade por *kernel* (KDE) separada por cluster.

Esse tipo de visualização é implementado via `seaborn.pairplot`. A SPLOM permite verificar, de forma simultânea, quais pares de atributos são mais discriminativos (maior separação visual entre clusters) e quais são altamente correlacionados dentro de cada cluster. Assim, na Figura 9 é apresentada a matriz de dispersão completa, com todos os 8 atributos. Os pontos são coloridos por cluster, com Cluster 0 em vermelho e Cluster 1 em azul.

Para uma análise com maior resolução visual, a Figura 10 apresenta a matriz de dispersão restrita aos 4 atributos de maior poder discriminativo, selecionados com base nos resultados da Subseção 2.1.1 e na análise de componentes principais:

- `total_active_power`: maior contribuição ao PC1 ($\approx 38\%$ da variância)
- `total_sm3`: maior sinal sazonal e cluster de inverno apresenta valores até $3\times$ maiores
- `mean_intensity`: correlacionada com P_{ativa} e segundo discriminador do PC1
- `total_sm_other`: consumo não medido e segundo discriminador no espaço PC2

2.3. Agrupamento de Dados de Características de Grãos de Trigo

2.3.1. Base de Dados

A base de dados contendo informações sobre grãos de três tipos de trigo, sendo eles Kama, Rosa e Canadense, é composta por 210 amostras e sete variáveis geométricas extraídas de imagens

de raio-X dos grãos, sendo elas área (*area*), perímetro (*perimeter*), compactidade (*compactness*), comprimento (*kernel_length*), largura (*kernel_width*), coeficiente de assimetria (*asymmetry_coef*) e comprimento do sulco ventral (*kernel_groove_length*). Além disso, para cada conjunto de informações geométricas, é informado o tipo de grão que gerou a amostra. O conjunto apresenta 70 amostras para cada um dos tipos de grão, sendo assim uma base com a classe de saída balanceada. Além disso, todas as demais características são numéricas e contínuas.

A Figura 11 mostra as distribuições das variáveis numéricas do conjunto de dados, bem como evidencia o balanceamento entre os tipos de trigo utilizados. Através da análise das distribuições, percebe-se que as variáveis apresentam magnitudes diferentes entre si e são assimétricas. Ademais, não há ocorrência de valores extremos nas distribuições, indicando a não-ocorrência de *outliers* no *dataset*. A Figura 12 mostra a matriz de correlação de Pearson entre as variáveis do conjunto de dados. Nela, podemos observar a alta colinearidade ($|r| > 0.8$) entre grande parte das características presentes no conjunto de dados, além de múltiplas ocorrências de correlação linear de média intensidade, com coeficientes de correlação entre 0,5 e 0,7. Dessa forma, muitas das variáveis presentes do conjunto de dados carregam informações semelhantes.

2.3.2. Agrupamento com K-Means

Com objetivo de avaliar o desempenho de um método não supervisionados na identificação de sementes de trigo de diferentes espécies, onde sabe-se, previamente, a quantidade de espécies de trigo que compõe o domínio, será utilizado o algoritmo K-means, que, no caso do conjunto de dados utilizado, terá o número de agrupamentos fixado em 3. Para desenvolvimento do modelo, decidiu-se dividir o conjunto de dados nos conjuntos de treinamento (70%) e de teste (30%), não sendo necessário um conjunto validação visto que não serão escolhidos hiperparâmetros.

O algoritmo K-means é prejudicado pela alta colinearidade entre variáveis de entrada do modelo, visto que um peso maior é dado para a informação que esse grupo de variáveis carrega em comum. Para atenuar esse problema, o PCA foi utilizado para gerar um novo espaço de características, utilizando o conjunto de treinamento. Para aplicação do PCA, as variáveis de entrada tiveram suas assimetrias corrigidas, através da transformação de Yeo-Johnson, e suas distribuições padronizadas, através das suas médias e desvios padrão. Portanto, os componentes principais computados pelo PCA serão fornecidos como entradas do modelo não supervisionado, ao invés das características originais do conjunto de dados, e os mesmos serão padronizados para utilização do método não supervisionado. Para avaliação, o número de componentes principais fornecidos como entradas do modelo será aumentado progressivamente, em ordem decrescente de variância relativa explicada, e serão medidos o ARI (Índice de Rand Ajustado) e o *accuracy* das predições para os conjuntos de treinamento e de teste. Ou seja, as iterações serão iniciadas apenas com PC1, adicionando, a cada iteração, a próxima componente em ordem decrescente de variância explicada, até a utilização de todos PCs. Para o cálculo da *accuracy*, o alinhamento entre as classes de saída e o *cluster* será feita através do método húngaro (algoritmo de Kuhn-Munkres). Para redução da influência da aleatoriedade, 1000 iterações do k-means foram utilizadas para ajuste da posição dos centroides para cada número de agrupamentos, onde o agrupamento com a menor inércia foi selecionado.

2.4. Agrupamento de Dados de Transações Semanais de Vendas

2.4.1. Base de Dados

O conjunto de dados de transações semanais de vendas registra a quantidade de itens vendidos de 811 produtos ao longo das 52 semanas do ano. Além dos valores absolutos, o conjunto disponibiliza essa mesma quantidade de forma normalizada, obtida por meio dos valores mínimo e máximo de vendas registrados para cada produto.

2.4.2. Agrupamento com K-means

Com objetivo de encontrar produtos com tendências de venda similares entre si, o algoritmo k-means foi utilizado. Como entradas do modelo, decidiu-se utilizar a quantidade de itens vendidos em cada uma das 52 semanas do ano normalizado, sendo dados já adequados para o agrupamento. Dessa forma, o agrupamento será feito com um conjunto de 811 entradas, cada uma com 52 dimensões (1 dimensão para cada semana). Como deseja-se descobrir quais produtos possuem tendências similares entre si, não é necessária a divisão em subconjuntos, como treinamento e teste, por exemplo.

Para encontrar os grupos de produtos com tendências similares, testou-se o número de *clusters* de 1 a 100, com passo de 1, e mediu-se a soma dos quadrados das distâncias (inércia) do modelo resultante. Para redução da influência da aleatoriedade, 1000 iterações do k-means foram utilizadas para ajuste da posição dos centroides para cada número de agrupamentos, onde o agrupamento com a menor soma dos quadrados das distâncias é selecionado. A escolha do número de *clusters* se deu através da análise da curva do cotovelo, que mostra a soma dos quadrados das distâncias em função do número de *clusters*.

3. Resultados e Discussões

3.1. Agrupamento de Dados de Consumo Residencial de Energia Elétrica

A análise de agrupamento do consumo residencial de energia elétrica foi executado sobre 1.420 perfis diários de consumo elétrico (17 de dezembro de 2006 a 26 de novembro de 2010), derivados por agregação temporal dos 2.049.436 registros minuto a minuto após pré-processamento. A Tabela 7 apresenta um resumo dos parâmetros e resultados quantitativos a serem explicitados nesta subseção.

Tabela 7. Resumo das métricas do processamento e agrupamento dos dados.

Parâmetro / Métrica	Valor
Registros originais (minuto)	2.075.259
Registros com NaN (% total)	25.979 (1,25%)
Registros após imputação + dropna()	2.049.436
Perfis diários válidos (≥ 1.200 min/dia)	1.420
Período coberto	2006-12-17 → 2010-11-26
k ótimo selecionado (Silhueta / CH)	2
k ótimo selecionado (Davies-Bouldin)	6
Silhueta Score final ($k = 2$)	0,2482
Índice CH ($k = 2$)	570,10
Índice DB ($k = 2$)	1,4534
Inércia WCSS ($k = 2$)	8.102,48
Accuracy k-NN no teste ($k_{NN} = 18$)	97,54%
Accuracy 10-fold CV	94,08% $\pm$ 2,66%
ARI (Ward HC versus k-Means, $n = 300$)	0,2896

Fonte: Autores (2026).

3.1.1. Seleção do Número Ótimo de Clusters

Na Figura 1, a inércia decresce monotonicamente de 8.102,5 (em $k = 2$) a 3.892,2 (em $k = 10$). A linha tracejada vermelha neste subgráfico assinala $k = 2$ (o valor ótimo segundo o critério de

Silhueta), servindo como referência cruzada para localizar o ponto correspondente na curva de inércia. O método do cotovelo procura o ponto de inflexão onde o ganho marginal começa a diminuir. Nesse caso, observa-se uma redução acelerada entre $k = 2$ e $k = 4$ (decréscimo de aproximadamente 2.060 unidades), seguida de reduções progressivamente mais modestas ($\Delta \approx 500$ por unidade de k entre $k = 4$ e $k = 10$). O cotovelo visual localiza-se em torno de $k = 3$ ou $k = 4$, sinalizando que acima desse valor o ganho em compacidade intra-cluster é marginal em frente ao aumento de complexidade do modelo.

O coeficiente de Silhueta médio $\bar{S}$ atingiu o valor máximo em $k = 2$ ($\bar{S} = 0,2482$), decrescendo para 0,2114 em $k = 3$ e oscilando entre 0,19 e 0,22 para valores maiores. Este resultado indica que, do ponto de vista da coesão intra-cluster e separação inter-cluster, a partição binária é a mais nítida geometricamente. O índice CH também foi maximizado em $k = 2$ ($CH = 570,1$), confirmando a conclusão do Silhueta. Este índice penaliza tanto a compressão intra-cluster como a separação inter-cluster. O valor decrescente com k evidencia que, a partir de $k = 3$, os novos clusters criados são menos separados dos seus vizinhos do que os fragmentos que os originaram.

O índice DB foi minimizado em $k = 6$ ($DB = 1,3741$), sugerindo que seis grupos seriam os mais compactos relativamente às suas distâncias inter-cluster. Contudo, dado que Silhueta e CH (métricas clássicas e amplamente empregadas na literatura para a seleção do k ótimo [12]) convergem unanimemente para $k = 2$, e dado que $k = 6$ não apresenta qualquer motivação semântica evidente nos dados, adotou-se $k = 2$ como valor definitivo. A concordância de três das quatro métricas em $k = 2$ confere robustez à escolha. A discordância do DB provavelmente reflete o fato de que, ao dividir os clusters heterogêneos de $k = 2$ em sub-grupos mais homogêneos, a métrica DB local melhora, mas ao custo de criar partições sem significado físico interpretável.

3.1.2. Análise de Silhueta por Amostra

No que diz respeito à Figura 2, há dois cenários principais:

- Para $k = 2$: ambos os clusters apresentam um perfil de silhueta relativamente homogêneo: a maioria das amostras tem $S(i) > 0$, embora com valores concentrados na faixa $[0,1; 0,4]$. O Cluster 1 (dias de baixo consumo, 759 observações) é ligeiramente mais coeso do que o Cluster 0. A ausência de dentes de serra pronunciados indica que não existem pontos com $S(i) < 0$ em quantidade significativa, ou seja, não há observações claramente classificadas de forma errônea.
- Para $k \in \{3, 4, 5\}$: observa-se uma degradação progressiva do perfil de silhueta, com clusters de tamanhos mais heterogêneos e frações crescentes de observações com $S(i) < \bar{S}$. Em particular, para $k = 4$, surge pelo menos um cluster de dimensão muito reduzida com silhueta inferior à média, sugerindo que a partição cria um grupo espúrio.

É possível concluir que a análise por amostra corrobora $k = 2$ como o valor ótimo, revelando que a variabilidade dos perfis diários de consumo dessa residência é melhor descrita por uma partição binária (alto versus baixo consumo) do que por subdivisões mais finas.

3.1.3. Projeção PCA dos Clusters k-Means e Distribuição Temporal

Os dois clusters à esquerda na Figura 3 aparecem claramente separados ao longo do eixo PC1. O Cluster 0 (alto consumo) ocupa a região de PC1 positivo elevado, enquanto o Cluster 1 (baixo consumo) concentra-se na região de PC1 baixo a negativo. Os centróides, assinalados por estrelas pretas, situam-se nas regiões de maior densidade de cada cluster. A separação não é perfeita, existe uma zona de sobreposição em torno de valores nulos de PC1, o que justifica o valor moderado do Silhueta (0,25) e é consistente com a transição gradual do consumo entre estações.

Já na direita da Figura 3, a correspondência com a informação sazonal é notável, já que os pontos de inverno (azul) concentram-se no extremo positivo de PC1 e coincidem quase inteiramente com o Cluster 0, enquanto os pontos de verão (laranja) ocupam o extremo negativo de PC1 e pertencem predominantemente ao Cluster 1. Outono (roxo) e primavera (verde) distribuem-se na

Tabela 8. Distribuição dos perfis diários por estação do ano e cluster.

Estação	Cluster 0 (Alto)	Cluster 1 (Baixo)	Total
Inverno (dez-fev)	276 (80,7%)	66 (19,3%)	342
Primavera (mar-mai)	179 (49,3%)	184 (50,7%)	363
Verão (jun-ago)	36 (10,0%)	323 (90,0%)	359
Outono (set-nov)	170 (47,8%)	186 (52,2%)	356

Fonte: Autores (2026).

região intermédia, sendo repartidos entre os dois clusters, o que explica a inexistência de um terceiro cluster claramente delimitado para as estações de transição. A visualização PCA sustenta a ideia de que PC1 é dominado pela dimensão de intensidade global de consumo, fortemente correlacionada com a temperatura sazonal e o uso do aquecimento.

A composição sazonal dos clusters, apresentada na Tabela 8, fornece a base quantitativa para a interpretação da Figura 4. No inverno, 80,7% dos dias são de alto consumo. Os meses de dezembro, janeiro e fevereiro apresentam consistentemente barras dominadas pelo Cluster 0 ao longo de todos os quatro anos de observação. No verão, 90,0% dos dias são de baixo consumo. Os meses de junho, julho e agosto estão quase inteiramente coloridos com o Cluster 1. Já na primavera e outono, a divisão é aproximadamente equitativa ($\approx 50/50$), confirmando que estas estações constituem um regime de transição em que a necessidade de aquecimento é variável e dependente de condições meteorológicas específicas de cada dia.

3.1.4. Análise do Classificador k-NN

A Figura 13 apresenta, à esquerda, as curvas de *accuracy* de treino e teste em função de k_{NN} e, à direita, a matriz de confusão do modelo final. A curva de treino parte de *accuracy* = 1,0 em $k_{NN} = 1$, já que com um único vizinho, o classificador reproduz perfeitamente os rótulos de treino mas generaliza de forma menos eficiente para novos dados. À medida que k_{NN} cresce, a fronteira de decisão é suavizada e a *accuracy* de treino decresce gradualmente. A curva de teste exhibe o comportamento oposto inicial, partindo de um valor inferior em $k_{NN} = 1$, aumentando até atingir o máximo em $k_{NN} = 18$ (*accuracy* = 0,9754), e depois decrescendo ligeiramente.

Esse comportamento demonstra que valores baixos de k implicam alta variância (sensibilidade a ruído), enquanto valores elevados implicam alto viés (fronteiras excessivamente suavizadas). A região entre as curvas de treino e teste representa a lacuna de generalização. O fato de essa lacuna ser relativamente estreita para $k_{NN} \geq 15$ indica que o modelo generaliza bem: os clusters são geometricamente bem separados no espaço de atributos normalizados.

A *accuracy* de validação cruzada foi de $94,08\% \pm 2,66\%$ (10 *folds*), valor inferior à *accuracy* no conjunto de teste isolado (97,54%), conforme esperado, já que a CV estima a *accuracy* de generalização de forma mais conservadora porque utiliza múltiplas partições, incluindo *folds* com proporções sazonais eventualmente menos favoráveis. O desvio padrão de 2,66% é modesto e indica estabilidade do classificador entre partições. Quanto à matriz de confusão também presente na Figura 13, a *precision* e o *recall* superiores a 97% em ambas as classes confirmam que os dois clusters são geometricamente bem separados no espaço de oito dimensões, com apenas 7 erros de classificação em 284 observações de teste.

3.1.5. Análise dos Dendogramas

No dendrograma de Ward na Figura 5 observa-se um grande salto de dissimilaridade entre a penúltima e a última fusão (fusão dos dois super-clusters finais), consistente com a existência de dois agrupamentos dominantes. A linha tracejada de corte posicionada logo abaixo da última fusão define precisamente $k = 2$. A simetria relativa dos dois ramos superiores confirma que os

clusters têm dimensões próximas (o que é compatível com 661 vs. 759 dias). A Ligação Ward, ao minimizar a variância intra-cluster a cada fusão, tende a produzir clusters compactos e de forma aproximadamente esférica (a mesma hipótese do k-Means) o que explica a maior concordância visual entre o dendrograma Ward e a partição k-Means.

Já na sua ampliação, na Figura 6, observa-se que os dois super-clusters se consolidam progressivamente a partir de grupos menores, com uma clara aceleração das distâncias de fusão nos níveis superiores. A estrutura hierárquica revela potenciais sub-agrupamentos internos a cada cluster:

- No ramo correspondente ao Cluster 0 (alto consumo), identificam-se sub-grupos que se fundem a distâncias intermédias, possivelmente correspondendo a dias de inverno com temperatura mais extrema versus dias de outono com aquecimento moderado.
- No ramo correspondente ao Cluster 1 (baixo consumo), o sub-agrupamento mais nítido poderá corresponder a dias de verão com consumo mínimo vs. dias de primavera/outono com consumo ligeiramente superior.

Esta análise hierárquica fornece informação adicional sobre a estrutura interna dos clusters que o k-Means, por construção, não captura, demonstrando a complementaridade entre os dois métodos. O número de observações indicado entre parênteses em cada folha representa o número de perfis diários agrupados naquele ramo (modo `lastp` do `scipy`). Folhas com número elevado indicam regiões de alta densidade no espaço de atributos.

3.1.6. Concordância entre Agrupamento Hierárquico e k-Means

Para quantificar o grau de concordância entre os rótulos produzidos pelo agrupamento hierárquico (HC) de Ward e os rótulos do k-Means (na amostra), foi calculado o Índice Rand Ajustado (ARI), que corresponde a uma versão corrigida pelo acaso do *Rand Index* (RI), medida baseada na proporção de pares de observações para os quais ambas as partições concordam quanto à coassociação em um mesmo grupo ou à separação em grupos distintos:

$$ARI = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]}$$

O ARI varia no intervalo $[-1, 1]$, onde 1 indica concordância perfeita (exceto por permutação de rótulos), 0 indica concordância aleatória, e valores negativos indicam menos concordância do que o esperado por acaso. Assim, o ARI calculado entre os rótulos do agrupamento hierárquico de Ward (cortado em $k = 2$) e os rótulos do k-Means, sobre a amostra de 300 dias, foi 0,2896. Este valor indica concordância moderada entre os dois métodos, acima do esperado por acaso ($ARI = 0$) mas substancialmente inferior à concordância perfeita ($ARI = 1$).

Pode-se concluir que os dias de outono e primavera ($\approx 50\%$ em cada cluster, conforme Tabela 8) estão na região de ambiguidade entre os dois regimes de consumo. Nessa zona, pequenas diferenças no critério de ligação (Ward para HC, distância Euclidiana ao centróide para k-Means) resultam em atribuições distintas para os mesmos pontos. Também, o HC opera sobre 300 dias (amostrados estratificadamente), enquanto o k-Means operou sobre os 1.420 dias completos. Os centróides k-Means foram calculados com base numa população maior e, portanto, são mais estáveis. A fronteira aprendida pelo HC pode diferir ligeiramente. Ainda, o k-Means otimiza globalmente a WCSS, ao passo que o agrupamento aglomerativo toma decisões locais e irreversíveis a cada fusão. Em espaços com clusters de geometria não perfeitamente esférica, as duas abordagens podem divergir nas regiões de fronteira.

3.2. Coeficiente de Inconsistência

A aplicação do algoritmo de Ligação de Ward ao conjunto de 1420 perfis diários produziu uma matriz de Ligação Z com 1419 fusões. O cálculo subsequente da matriz de inconsistência

com profundidade $d = 2$ resultou nas seguintes estatísticas globais para os coeficientes máximo $c_{\max} = 1,1547$, médio $\bar{c} = 0,5608$ e mediano $\tilde{c} = 0,7071$. A amplitude reduzida do coeficiente ($c \in [0,00; 1,15]$) constitui, por si só, um resultado analiticamente relevante. Em conjuntos de dados com grupos bem separados, espera-se que as fusões inter-cluster do topo do dendrograma apresentem coeficientes substancialmente superiores a 2,0. O fato de nenhuma fusão superar 1,155 indica que as transições entre os padrões de consumo sazonais são graduais, sem fronteiras abruptas no espaço de atributos normalizados.

A Figura 7 ilustra este fenômeno nos seus dois gráficos. O gráfico da esquerda exibe todos os coeficientes não-nulos (aproximadamente 1100 fusões, a partir da primeira com vizinhança suficiente para o cálculo com $d = 2$). Observa-se uma densa faixa horizontal entre $c \approx 0,7$ e $c \approx 1,15$, com uma linha pontilhada de referência em $c = 1,0$. A fusão decisiva ($k = 2$, índice 1418) encontra-se marcada em vermelho no extremo superior direito, com $c = 1,1236$: valor ligeiramente acima da média do conjunto de alto nível, confirmando que a fusão raiz é a mais anômala em relação ao seu entorno hierárquico. O gráfico da direita amplifica as últimas 60 fusões, com o coeficiente oscilando entre 0,75 e 1,155, sem tendência monotônica clara, o que reforça que não existe uma fronteira única e dominante nos níveis intermediários do dendrograma. A fusão raiz, porém, destaca-se como o ponto de corte mais natural, combinando o maior coeficiente de inconsistência do nível superior ($c = 1,1236$) com o maior salto de altura ($\Delta h = 29,03$). A Tabela 5 (últimas 15 fusões) confirma que os coeficientes das fusões de alto nível oscilam em torno de 1,0, sem tendência de crescimento monotônico à medida que se sobe na hierarquia.

3.2.1. Determinação do Número e Caracterização dos Clusters

A Tabela 6, primeiro método, apresenta o resultado mais informativo para a seleção de k . O salto de altura $\Delta h(k = 2) = 29,03$ é o maior dos saltos, já que o segundo maior valor é $\Delta h(k = 3) = 9,21$, que é em torno de 3,15 vezes menor. Esta discrepância constitui evidência forte de que a hierarquia Ward identifica dois grupos no *dataset*, com uma fronteira principal localizada entre as fusões de índice 1417 (altura = 46,95) e 1418 (altura = 75,98). O segundo método, baseado na maior lacuna entre alturas consecutivas nas últimas 15 fusões, converge para o mesmo resultado. A lacuna de 29,03 entre as fusões 1417 e 1418 supera todos os demais por larga margem, já que as três maiores lacunas restantes são 9,21, 5,62 e 3,47.

A atribuição final dos rótulos via `fcluster(Z, t=2, criterion='maxclust')` produziu Cluster 0 de 667 dias (47,0%), com perfil de consumo reduzido (primavera/verão), e Cluster 1 de 753 dias (53,0%), com perfil de consumo elevado (outono/inverno). A Figura 8 torna evidente essas duas partições. Os dois grandes ramos coloridos – laranja (Cluster 0, ramo esquerdo) e verde (Cluster 1, ramo direito) – subdividem-se progressivamente sem se cruzarem abaixo da linha de corte tracejada a vermelho (posicionada na altura de corte $h_{\text{corte}} = 61,47$, ponto médio entre as fusões 1417 e 1418). O único nó cinza, acima do limiar, é a própria fusão raiz responsável pela união, na altura 75,98.

Quanto à assimetria entre os dois ramos do dendrograma, o esquerdo apresenta subestruturas internas em alturas menores ($h \leq 38$), enquanto o ramo direito tem subestruturas em alturas levemente superiores ($h \leq 47$). Isso indica que o Cluster 1 (inverno) possui maior variabilidade interna, provavelmente devido à diferença entre dias de inverno muito frio (aquecimento intensivo) e dias de outono/início de primavera (aquecimento moderado).

3.2.2. Análise das Matrizes de Dispersão

A Figura 9 apresenta a matriz de dispersão 8×8 dos 1420 perfis diários, com os dois clusters coloridos em vermelho (Cluster 0) e azul (Cluster 1). Sobre as distribuições marginais, localizadas na diagonal da SPLOM:

- `total_active_power`: distribuição bimodal com os dois clusters visivelmente separados. O Cluster 0 apresenta moda em torno de 1.400 kW·min/dia. Já o Cluster 1 apresenta moda em torno de 1.700 kW·min/dia.

- `total_sm3`: é o atributo com maior separação inter-cluster. O Cluster 0 concentra-se em valores de ~ 9.000 Wh/dia, enquanto o Cluster 1 apresenta moda em ~ 13.000 Wh/dia, com distribuição mais larga. Isso mostra que o aquecimento central eleva-se no inverno europeu, período que domina o Cluster 1.
- `mean_voltage`: ambos os clusters apresentam distribuições bimodais em torno de 238–242 V. O Cluster 0 (verão) exibe tensão ligeiramente superior, enquanto o Cluster 1 (inverno) apresenta tensão ligeiramente inferior. Isso mostra que correntes mais elevadas no inverno provocam quedas de tensão maiores na linha de distribuição, reduzindo a tensão média observada.
- `mean_intensity`: bimodal, com separação inter-cluster proporcional à `total_active_power`, o que é esperado pela relação $P = V \cdot I$.
- `total_sm1` e `total_sm2`: distribuições fortemente assimétricas à esquerda, concentradas próximo de zero, com cauda longa e sobreposição quase total entre os clusters. Esses atributos não são discriminativos para a separação sazonal, confirmando que o uso de cozinha e lavanderia é independente da estação do ano.
- `total_sm_other`: o Cluster 0 (verão/primavera) apresenta valores mais elevados (~ 20.000 Wh/dia) do que o Cluster 1 (~ 15.000 Wh/dia) para esse atributo. Esse resultado, aparentemente contraintuitivo, é coerente com a equação de derivação do atributo (Subseção 2.1.1). No verão, a potência ativa total é moderada, mas `total_sm3` é muito baixa, tornando esse resíduo elevado. Esse resíduo pode incluir aparelhos de climatização doméstica não medidos individualmente.

Já a Figura 10 foca nos 4 atributos de maior poder discriminativo. A maior resolução facilita a interpretação dos padrões ressaltados a seguir:

- `total_active_power` $\times$ `total_sm3`: é o par com maior separação inter-cluster observável. O Cluster 0 (vermelho) concentra-se na região de `total_sm3` < 12.000 Wh/dia e `total_active_power` < 2.000 kW·min/dia. O Cluster 1 (azul) estende-se para `total_sm3` > 10.000 Wh/dia, com maior dispersão para valores elevados. Contudo, as nuvens sobrepõem-se na região central ($8.000 \leq \text{total_sm3} \leq 15.000$ Wh/dia).
- `total_active_power` $\times$ `mean_intensity`: os 1420 pontos distribuem-se sobre uma reta relativamente estreita, refletindo a relação física determinística entre as duas grandezas. Os clusters não são visualmente separáveis nesta projeção bidimensional.
- `total_sm3` $\times$ `mean_intensity`: separação inter-cluster bem visível ao longo do eixo da `total_sm3`, com ambos os clusters formando nuvens distintas na direção vertical, mas muito próximas na direção horizontal (intensidade).
- `total_sm_other` $\times$ `total_sm3`: os dois clusters exibem uma relação complementar, isto é, quando `total_sm3` é alto (Cluster 1), `total_sm_other` tende a ser menor. Essa relação inversa moderada confirma a hipótese de que o consumo não medido reflete aparelhos de uso sazonal alternativos ao aquecimento central.

3.3. Agrupamento de Dados de Características de Grãos de Trigo

Após a aplicação do PCA nas características de entrada do conjunto de dados de características dos grãos de trigo, 7 componentes principais (PCs) foram gerados, cujas variâncias explicadas relativas e o a variância explicada acumulada são exibidas na Figura 14. Pode-se observar que, a variância do conjunto de entrada é explicada quase totalmente com apenas 3 componentes principais, evidenciando quanta informação redundante é carregada pelas características de entrada, detectado através das correlações de Pearson. Dessa forma, o impacto da redundância de informação em múltiplas variáveis foi reduzido, com objetivo de melhorar a performance do algoritmo k-means.

Variando-se a quantidade de entradas do modelo, desde apenas com PC1 até com todos os 7 PCs, mensurou-se o desempenho do modelo com as métricas ARI e *accuracy*, cujas medições em função do número de componentes utilizados é exibido na Figura 15. Percebe-se que, além do PC1, o PC5 teve grande contribuição para a melhora das métricas do modelo. Mesmo com o PC5

tendo uma variância explicada próxima de zero, o mesmo apresenta informações discriminativas relevantes para o algoritmo não supervisionado, carregando informação, principalmente, da largura e do comprimento do grão, como pode ser identificado através dos coeficientes angulares dos componentes principais exibido na Figura 16. Além disso, percebe-se que, em geral, há uma melhora na capacidade preditiva do k-means com o aumento do número de componentes principais fornecidos, onde, na melhor configuração para o conjunto treinamento e de teste foi obtida com 5 PCs, onde a adição de mais PCs não fez diferença significativa na performance do modelo. A Tabela 9 mostra as métricas de desempenho preditivo do k-means para os conjuntos de treinamento e de teste, indicando que o modelo é adequado para identificação dos tipos de trigo através das características geométricas dos grãos, visto que o modelo apresenta um baixo *bias*, indicado pelo bom desempenho no conjunto de treinamento, e uma baixa variância, visto que o modelo apresenta um desempenho marginalmente superior, resultante da aleatoriedade da divisão dos dados, quando exposto à novas amostras.

Tabela 9. Desempenho do modelo k-means utilizando as sete componentes principais.

Métrica	Treinamento	Teste
Accuracy (%)	95,24	98,41
Índice de Rand Ajustado	0,8633	0,9520

Fonte: Autores (2026).

3.4. Agrupamento de Dados de Transações Semanais de Vendas

Após variar o número de *clusters* do k-means, obteve-se a curva do cotovelo exibida na Figura 17. Observa-se que, para um número de grupos entre 6 e 7, não há mais melhora expressiva da inércia do modelo. Por meio da análise da curva, escolheu-se o número de *clusters* igual a 6. O modelo foi então treinado novamente com o número de *clusters* determinado, utilizando todo o conjunto de dados. Após a estabilização, os centróides resultantes, cada um com 52 dimensões (uma dimensão para cada semana do ano), são exibidos na Figura 18. Por meio da análise das curvas de cada centróide, identifica-se que o centróide do primeiro *cluster* agrupou produtos com número de vendas normalizado alto na primeira metade das semanas consideradas, com queda na segunda metade, mantendo as vendas estáveis dentro de cada um desses dois intervalos. O segundo grupo apresenta número de vendas normalizado baixo durante todo o ano. O terceiro grupo também exibe número de vendas normalizado baixo, mas com tendência de alta ao longo do tempo. O quarto grupo apresenta número de vendas na faixa média, aumentando consideravelmente no meio do período considerado. O quinto grupo é similar ao quarto, mas com vendas normalizadas mais altas na primeira metade dos intervalos e com queda mais acentuada na segunda metade do período. O sexto grupo, por fim, apresenta comportamento similar ao do primeiro, porém com valores de vendas normalizadas menores, mais próximos de 0,5. Conclui-se, portanto, que o k-means se mostra adequado para identificar grupos de produtos com tendências de venda semelhantes entre si e conseguindo distinguir tendências diferentes entre os produtos considerados.

4. Conclusão


Este trabalho aplicou e avaliou técnicas de agrupamento não supervisionado, com ênfase no algoritmo k-means, sobre três conjuntos de dados de naturezas distintas, abrangendo tanto a recuperação de estruturas conhecidas quanto a identificação de padrões previamente desconhecidos. No conjunto de grãos de trigo, no qual o número de classes era conhecido a priori, o k-means precedido da análise de componentes principais mostrou-se capaz de recuperar as espécies com alta fidelidade, evidenciando que a redução da redundância entre as variáveis de entrada favorece

o desempenho do método. No conjunto exploratório de transações semanais de vendas, o algoritmo revelou grupos de produtos com tendências de venda qualitativamente diferentes ao longo do ano, demonstrando sua utilidade na descoberta de padrões em cenários sem rótulos conhecidos. No conjunto de consumo residencial de energia elétrica, a caracterização dos perfis diários convergiu para uma partição coerente e com clara interpretação sazonal, validada por um classificador supervisionado e enriquecida pelo contraste com o agrupamento hierárquico, que revelou a natureza gradual das transições entre os regimes de consumo. De forma geral, os resultados demonstram que o k-means é uma ferramenta adequada e versátil tanto para validar estruturas conhecidas quanto para explorar padrões latentes, desde que precedido de pré-processamento apropriado, e que a seleção criteriosa do número de grupos e a comparação com métodos hierárquicos fornecem informação complementar que enriquece a análise.

Referências


1. Jain, A.K. Data clustering: 50 years beyond K-means. *Pattern Recognition Letters* **2010**, 31, 651–666.
2. MacQueen, J. Some Methods for Classification and Analysis of Multivariate Observations. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. University of California Press, 1967, Vol. 1, pp. 281–297.
3. Jolliffe, I.T. *Principal Component Analysis*, 2 ed.; Springer: New York, 2002.
4. Jolliffe, I.T.; Cadima, J. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences* **2016**, 374, 20150202.
5. Parsa, I. KDD Cup 1998. UCI Machine Learning Repository, 1998. DOI: <https://doi.org/10.24432/C5401H>.
6. Hebrail, G.; Berard, A. Individual Household Electric Power Consumption. UCI Machine Learning Repository, 2006. DOI: <https://doi.org/10.24432/C58K54>.
7. Balbinot, A. ELE318 - Aula 05 C - Parte 3/3. Slides de aula, Inteligência Computacional I, 2026.
8. Rousseeuw, P.J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of computational and applied mathematics* **1987**, 20, 53–65.
9. Caliński, T.; Harabasz, J. A dendrite method for cluster analysis. *Communications in Statistics-theory and Methods* **1974**, 3, 1–27.
10. Davies, D.L.; Bouldin, D.W. A cluster separation measure. *IEEE transactions on pattern analysis and machine intelligence* **1979**, pp. 224–227.
11. Hartigan, J.A.; Wong, M.A. Algorithm AS 136: A k-means clustering algorithm. *Journal of the royal statistical society. series c (applied statistics)* **1979**, 28, 100–108.
12. Öztürk, F.E.; Demirel, N. Comparison of the methods to determine optimal number of cluster. *Veri Bilimi* **2023**, 6, 34–45.

Figura 9. Matriz de dispersão completa dos 1420 perfis diários, coloridos por cluster (HC Ward, $k = 2$).




Fonte: Autores (2026).

Figura 10. Matriz de dispersão focada nos 4 atributos mais discriminativos.




Fonte: Autores (2026).

Figura 11. Histogramas das variáveis da base de dados de sementes de trigo.


Fonte: Autores (2026).

Figura 12. Matrix de correlação de Pearson das variáveis da base de dados de sementes de trigo.




Fonte: Autores (2026).


Figura 13. Curvas de *accuracy* de treino e teste em função de k_{NN} (esquerda) e matriz de confusão do classificador k-NN com o k ótimo (direita).




Fonte: Autores (2026).

Figura 14. Variância explicada relativa e sua acumulada das componentes principais.


Fonte: Autores (2026).

Figura 15. ARI e *accuracy* do k-means na predição do tipo de trigo, variando-se o número de PCs de entrada.

Fonte: Autores (2026).


Figura 16. Coeficientes angulares das características de entrada para cada componentes principal.

Fonte: Autores (2026).

Figura 17. Curva do cotovelo, relacionando o número de grupos com a soma dos quadrados das distâncias intragrupo.

Fonte: Autores (2026).

Figura 18. Centróides obtidos para os seis grupos, representando o perfil semanal de demanda normalizada característico de cada grupo.



Fonte: Autores (2026).